

著录项目信息

名称：一种基于标准化流式先验的噪声参数估计方法

类型：发明

申请人：


发明人名单：

第一发明人以及第一发明人身份证号码：刘琦 370911199803186025

说明书摘要

本发明公开了一种基于标准化流式先验的噪声参数估计方法,属于噪声图像合成技术领域,主要包括以下步骤:使用传感器标定数据预训练标准化流模型,作为生成式先验;准备 SIDD 数据集中的干净 raw 域图像作为模型输入,根据实际场景的生成需要,采集真实 raw 域图像作为判别器输入,迭代训练神经网络;保存训练好的模型,基于标准化流估计噪声模型的参数,生成特定于相机传感器的噪声 raw 域图像。通过基于标准化流的噪声建模,将噪声模型的参数作为随机变量进行研究,通过概率模型来拟合其分布,模拟出更多样化的噪声图像,以此合成训练样本更接近测试图像的域。

摘要附图



1. 一种基于标准化流式先验的噪声参数估计方法，其特征在于，主要包括以下步骤：使用传感器标定数据预训练标准化流模型，作为生成式先验；准备 SIDD 数据集中的干净 raw 域图像作为模型输入，根据实际场景的生成需要，采集真实 raw 域图像作为判别器输入，迭代训练神经网络；保存训练好的模型，基于标准化流估计噪声模型的参数，生成特定于相机传感器的噪声 raw 域图像。
2. 根据权利要求 1 所述的基于标准化流式先验的噪声参数估计方法，其特征在于，所述使用传感器标定数据预训练标准化流模型具体过程为：神经网络生成式模型从零均值各向同性高斯分布 Z_k 中采样，经过标准化流模块的映射，估计出复杂噪声参数分布，从估计出的复杂噪声参数分布中采样得到噪声模型的四个参数；四个参数生成对应的噪声加到干净图像上获得最终对应的噪声图，整个模型通过最小化变换后分布的负对数似然函数来训练。
3. 根据权利要求 2 所述的基于标准化流式先验的噪声参数估计方法，其特征在于，所述噪声模型，如式 1 所示：

$$N = KN_p + N_{read} + N_r + N_q \quad \langle \text{式 1} \rangle$$

其中， N_p 是光子入射噪声； K 是 0 到 1 之间的参数，在此作为增益系数；某个像素点位置采集电子之后，被传感器集成、放大，并在曝光时间结束时作为可测量的电荷或电压读出，在该过程中产生的噪声为读取噪声，用 N_{read} 表示； N_r 是行噪声； N_q 是量化噪声；噪声模型中需要估计的四个参数为： K 是增益系数， σ_r 是行噪声 N_r 中所需的方差， σ_{read} 是读取噪声 N_{read} 中所需的方差， q 是量化噪声 N_q 所需的量化步长。

4. 根据权利要求 3 所述的基于标准化流式先验的噪声参数估计方法，其特征在于，所述 K 的估计方法具体为：设 $k \in K$ 为噪声参数采样值， K 为噪声参数随机变量， $Z_n \in Z$ 为相应的隐变量值， Z 为对应的隐空间随机变量； k 和 Z_n 服从概率分布 p_k 和 p_z ，定义参数为 θ 的双射 $f_\theta: K \rightarrow Z$ ；对于噪声参数 k ，可以在隐空间中编码一个隐变量 $z_n = f_\theta(k)$ ，所以 k 可以通过对应的反函数得到 $k = f_\theta^{-1}(z_k)$ ， k 的概率密度函数如式 2 所示：

$$p_K(k) = p_Z(f_\theta(k)) \left| \det\left(\frac{\partial f_\theta(k)}{\partial k}\right) \right| \quad \langle \text{式 2} \rangle$$

p_Z 是简单的零均值各向同性高斯分布，基于最大化负对数似然估计，转换函数参数 θ 可以通过最小化损失函数得到式 3：

$$L(k; \theta) = -\log p_Z(f_\theta(k)) - \sum_{n=1}^N \log \left| \det\left(\frac{\partial f_\theta^n(h^{n-1})}{\partial h^{n-1}}\right) \right| \quad \langle \text{式 3} \rangle$$

标准化流模块采用跟 Glow 模型相同的双射变换层，一是仿射变换层，可以捕获任意的图像尺寸即像素之间的相关性，本发明的仿射变换曾使用小型全连接神经网络（FCN）来进行维度的缩放，二是 1x1 卷积层，实现通道之间的线性变换；激活层采用 tanh 激活函数。

5. 根据权利要求 1 所述的基于标准化流式先验的噪声参数估计方法，其特征在于，使用 Tukey lambda 分布建模读取噪声， $N_{read} \sim TL(\lambda; 0, \sigma_{TL})$ ，其中 σ_{TL} 表示尺度参数，在零均值噪声假设下，位置参数被设置为 0；所述行噪声值 N_r 从尺度参数为 σ_r 的零均值高斯分布中采样， $N_r \sim N(0, \sigma_r)$ ，然后将其作为对每一行像素点的偏移量进行相加；模拟电压信号使用 ADC 被量化为离散值时会引入量化噪声 N_q ， $N_q \sim U(-\frac{1}{2q}, \frac{1}{2q})$ ，其中， q 为其中为量化步长， U 表示均匀分布。

6. 根据权利要求 1 所述的基于标准化流式先验的噪声参数估计方法，其特征在于，所述使用智能手机图像去噪数据集 SIDD，该数据集使用了 5 个具有代表性的智能手机摄像头，从 10 个场景中提取约 30000 个真实场景噪声图像，该数据集可对降噪算法进行基准测试；所述真实场景噪声图像使用该数据集中原始 raw 图像，将原始图像数据集划分成 50 万个大小为 64x64 像素的图像块，按照 7: 3 的比例划分训练集和测试集。

7. 根据权利要求 6 所述的基于标准化流式先验的噪声参数估计方法，其特征在于，所述使用传感器标定数据预训练标准化流模型的具体过程为：使用训练集进行模型训练，假设数据集中的噪声是空间不变的，使用 PatchGan 鉴别器作为对抗训练的鉴别器，将 SIDD 数据集划分成 64×64 大小的块，批大小设置为 16，所有的模型在单卡 3080T GPU 上被迭代训练 2×10^5 次，使用 Adam 作为优化器，学习率一开始被设置为 2×10^{-4} ，每迭代 5000 次学习率降低。

一种基于标准化流式先验的噪声参数估计方法

技术领域

本发明属于噪声图像合成技术领域，尤其涉及一种基于标准化流式先验的噪声参数估计方法。

背景技术

噪声建模和去噪是底层计算机视觉的基本任务，图像噪声可以描述为测量结果与实际信号之间的偏差。给定一个观测到的图像 \tilde{I} 和它对应的无噪声图像 I ，它们的关系如下：

$$\tilde{I} = I + n$$

其中， n 为图像噪声。

对于依赖于 CMOS 的智能手机摄像头来说，当传感器上显示出视觉较为明显的噪声时，会极大地影响人们的使用体验。

现有基于数据驱动的去噪方法主要是通过设计噪声模型来合成更真实的训练数据。

假设像素点位置的噪声值为 n_i ， n_i 满足独立同分布，目前有以下几种情况：

(1) 加性高斯白噪声 (Additive white Gaussian noise, AWGN)，如下所示：

$$n_i \sim N(0, \sigma^2)$$

其中， N 表示高斯分布，均值为0，方差为 σ^2 。

(2) 泊松-高斯分布(P-G distribution)，图像噪声由信号相关和信号无关的两部分组成，与信号相关的噪声用泊松过程来建模，与信号无关的噪声用高斯过程来建模，如下所示：

$$n_i \sim \alpha P(I_i) - I_i + N(0, \sigma^2)$$

其中， P 表示泊松分布， N 表示高斯分布， I_i 为像素点 i 位置的值， α 为0到1之间的参数， σ^2 是高斯分布的方差。

(3) 异方差高斯分布，如下所示：

$$n_i \sim N(0, \beta_1 I + \beta_2)$$

其中， I 表示表示图像的像素值， N 表示高斯分布， β_1 和 β_2 均大于0，描述了信号强度与噪声水平之间的关系。一些相机在其保存的 raw-rgb 图像中包括一

个由制造商校准的异方差高斯噪声模型，但该模型参数较少，只是真实传感器噪声的一个近似。

发明人认为，现有基于神经网络的去噪算法使用数据集采集难度大，参数量较少，不同传感器由于参数标定不同，使得训练出的网络不具备泛化能力，不符合真实传感器成像过程中噪声的形成过程，不能生成更加真实的噪声，为此，需要设计出一种基于标准化流式先验的噪声参数估计方法。

需要说明的是，在上述背景技术部分公开的信息仅用于加强理解本公开的背景，并且因此可以包括不构成现有技术的信息。

发明内容

发明人通过研究发现，目前由于缺乏大规模的真实 raw 域图像去噪标定数据集，一般通过设计噪声模型来合成更真实的训练数据，基于神经网络的去噪算法使用数据集采集难度大，参数量较少，不同传感器由于参数标定不同，使得训练出的网络不具备泛化能力，不符合真实传感器成像过程中噪声的形成过程，不能生成更加真实的噪声，而标准化流的过程是通过具有已知分布的随机变量通过一系列可微、可逆映射的转换生成其他分布的过程，基于标准化流的方法不会面临模型坍塌的问题，它们有更为准确的采样和对概率密度的估计。

鉴于以上技术问题中的至少一项，本公开提供了一种基于标准化流式先验的噪声参数估计方法，具体技术方案如下：

一种基于标准化流式先验的噪声参数估计方法，主要包括以下步骤：使用传感器标定数据预训练标准化流模型，作为生成式先验；准备 SIDD 数据集中的干净 raw 域图像作为模型输入，根据实际场景的生成需要，采集真实 raw 域图像作为判别器输入，迭代训练神经网络；保存训练好的模型，基于标准化流估计噪声模型的参数，生成特定于相机传感器的噪声 raw 域图像。

在本公开的一些实施例中，所述使用传感器标定数据预训练标准化流模型具体过程为：神经网络生成式模型从零均值各向同性高斯分布 Z_k 中采样，经过标准化流模块的映射，估计出复杂噪声参数分布，从估计出的复杂噪声参数分布中采样得到噪声模型的四个参数；四个参数生成对应的噪声加到干净图像上获得最终对应的噪声图，整个模型通过最小化变换后分布的负对数似然函数来训练。

在本公开的一些实施例中，所述噪音模型，如式 1 所示：

$$N = KN_p + N_{read} + N_r + N_q \quad \langle \text{式 1} \rangle$$

其中, N_p 是光子入射噪声, 服从泊松分布, 这类噪声极大地依赖于信号强度; K 是 0 到 1 之间的参数, 在此作为增益系数; 某个像素点位置采集电子之后, 被传感器集成、放大, 并在曝光时间结束时作为可测量的电荷或电压读出, 在该过程中产生的噪声为读取噪声, 用 N_{read} 表示; N_r 是行噪声; N_q 是量化噪声; 噪声模型中需要估计的四个参数为: K 是增益系数, σ_r 是行噪声 N_r 中所需的方差, σ_{read} 是读取噪声 N_{read} 中所需的方差, q 是量化噪声 N_q 所需的量化步长。

在本公开的一些实施例中, 所述 K 的估计方法具体为: 设 $k \in K$ 为噪声参数采样值, K 为噪声参数随机变量, $Z_n \in Z$ 为相应的隐变量值, Z 为对应的隐空间随机变量; k 和 Z_n 服从概率分布 p_k 和 p_z , 定义参数为 θ 的双射 $f_\theta: K \rightarrow Z$; 对于噪声参数 k , 可以在隐空间中编码一个隐变量 $z_n = f_\theta(k)$, 所以 k 可以通过对应的反函数得到 $k = f_\theta^{-1}(z_k)$, k 的概率密度函数如式 2 所示:

$$p_K(k) = p_Z(f_\theta(k)) \left| \det\left(\frac{\partial f_\theta(k)}{\partial k}\right) \right| \quad \langle \text{式 2} \rangle$$

p_Z 是简单的零均值各向同性高斯分布, 基于最大化负对数似然估计, 转换函数参数 θ 可以通过最小化损失函数得到式 3:

$$L(k; \theta) = -\log p_Z(f_\theta(k)) - \sum_{n=1}^N \log \left| \det\left(\frac{\partial f_\theta^n(h^{n-1})}{\partial h^{n-1}}\right) \right| \quad \langle \text{式 3} \rangle$$

标准化流模块采用跟 Glow 模型相同的双射变换层, 一是仿射变换层, 可以捕获任意的图像尺寸即像素之间的相关性, 本发明的仿射变换曾使用小型全连接神经网络 (FCN) 来进行维度的缩放, 二是 1x1 卷积层, 实现通道之间的线性变换; 激活层采用 tanh 激活函数。

在本公开的一些实施例中, 使用 Tukey lambda 分布建模读取噪声, 这是一个分布家族, 可以近似一些常见分布; $N_{read} \sim TL(\lambda; 0, \sigma_{TL})$, 其中 σ_{TL} 表示尺度参数, 在零均值噪声假设下, 位置参数被设置为 0; λ 是 Tukey 分布的一种形状参数, 用于控制分布的偏态和尾部厚度, 当 $\lambda=0$ 时, Tukey 分布退化为标准正态分布; λ 较小时, 分布呈现出类似于一个对称的钟形曲线, 尾部比标准正态分布更厚; λ 较大时, 分布呈现出右偏或左偏的形状, 尾部更加厚重, 呈现出重尾特征; 此处因噪声分布具有长尾特性, 所以选取 lambda 值较大, 用来拟合噪声特性; 所述行噪声值 N_r 从尺度参数为 σ_r 的零均值高斯分布中采样, $N_r \sim N(0, \sigma_r)$, 然后将其作为对每一行像素点的偏移量进行相加; 模拟电压信号使用 ADC 被量化

为离散值时会引入量化噪声 N_q , $N_q \sim U(-\frac{1}{2q}, \frac{1}{2q})$, 其中, q 为其中为量化步长,

U 表示均匀分布。

在本公开的一些实施例中，所述使用智能手机图像去噪数据集 SIDD，该数据集使用了 5 个具有代表性的智能手机摄像头，从 10 个场景中提取约 30000 个真实场景噪声图像，该数据集可对降噪算法进行基准测试；所述真实场景噪声图像使用该数据集中原始 raw 图像，将原始图像数据集划分成 50 万个大小为 64×64 像素的图像块，按照 7:3 的比例划分训练集和测试集。

在本公开的一些实施例中，所述使用传感器标定数据预训练标准化流模型的具体过程为：使用训练集进行模型训练，假设数据集中的噪声是空间不变的，使用 PatchGAN 鉴别器作为对抗训练的鉴别器，将 SIDD 数据集划分成 64×64 大小的块，批大小设置为 16，所有的模型在单卡 3080T GPU 上被迭代训练 2×10^5 次，使用 Adam 作为优化器，学习率一开始被设置为 2×10^{-4} ，每迭代 5000 次学习率降低。

相比较现有技术而言，本发明具有以下有益效果：

1、本发明通过基于标准化流的噪声建模，将噪声模型的参数作为随机变量进行研究，通过概率模型来拟合其分布，模拟出更多样化的噪声图像，以此合成训练样本更接近测试图像的域；

2、标准化流的过程是通过具有已知分布的随机变量通过一系列可微、可逆映射的转换生成其他分布的过程，基于标准化流的方法不会面临模型坍塌的问题，它们有更为准确的采样和对概率密度的估计。

附图说明

图 1 为本发明的整体流程框架图；

具体实施方式

为了更好地了解本发明的目的、结构及功能，下面将结合本发明实施例中的附图，对本发明实施例中的技术方案进行清楚、完整地描述，显然，所描述的实施例是本发明一部分实施例，而不是全部的实施例。

一种基于标准化流式先验的噪声参数估计方法，主要包括以下步骤：使用传感器标定数据预训练标准化流模型，作为生成式先验；准备 SIDD 数据集中的干净 raw 域图像作为模型输入，根据实际场景的生成需要，采集真实 raw 域图像作为判别器输入，迭代训练神经网络；保存训练好的模型，基于标准化流估计噪声模型的参数，生成特定于相机传感器的噪声 raw 域图像。

在本公开的一些实施例中，所述使用传感器标定数据预训练标准化流模型具体过程为：神经网络生成式模型从零均值各向同性高斯分布 Z_k 中采样，经过标准化流模块的映射，估计出复杂噪声参数分布，从估计出的复杂噪声参数分布中采样得到噪声模型的四个参数；四个参数生成对应的噪声加到干净图像上获得最终对应的噪声图，整个模型通过最小化变换后分布的负对数似然函数来训练。

在本公开的一些实施例中，所述噪音模型，如式 1 所示：

$$N = KN_p + N_{read} + N_r + N_q \quad \langle \text{式 1} \rangle$$

其中， N_p 是光子入射噪声； K 是 0 到 1 之间的参数，在此作为增益系数；某个像素点位置采集电子之后，被传感器集成、放大，并在曝光时间结束时作为可测量的电荷或电压读出，在该过程中产生的噪声为读取噪声，用 N_{read} 表示； N_r 是行噪声； N_q 是量化噪声；噪声模型中需要估计的四个参数为： K 是增益系数， σ_r 是行噪声 N_r 中所需的方差， σ_{read} 是读取噪声 N_{read} 中所需的方差， q 是量化噪声 N_q 所需的量化步长。

在本公开的一些实施例中，所述 K 的估计方法具体为：设 $k \in K$ 为噪声参数采样值， K 为噪声参数随机变量， $Z_n \in Z$ 为相应的隐变量值， Z 为对应的隐空间随机变量； k 和 Z_n 服从概率分布 p_k 和 p_z ，定义参数为 θ 的双射 $f_\theta: K \rightarrow Z$ ；对于噪声参数 k ，可以在隐空间中编码一个隐变量 $z_n = f_\theta(k)$ ，所以 k 可以通过对应的反函数得到 $k = f_\theta^{-1}(z_k)$ ， k 的概率密度函数如式 2 所示：

$$p_K(k) = p_Z(f_\theta(k)) \left| \det\left(\frac{\partial f_\theta(k)}{\partial k}\right) \right| \quad \langle \text{式 2} \rangle$$

p_z 是简单的零均值各向同性高斯分布，基于最大化负对数似然估计，转换函数参数 θ 可以通过最小化损失函数得到式 3：

$$L(k; \theta) = -\log p_z(f_\theta(k)) - \sum_{n=1}^N \log \left| \det\left(\frac{\partial f_\theta^n(h^{n-1})}{\partial h^{n-1}}\right) \right| \quad \langle \text{式 3} \rangle$$

标准化流模块采用跟 Glow 模型相同的双射变换层，一是仿射变换层，可以捕获任意的图像尺寸即像素之间的相关性，本发明的仿射变换曾使用小型全连接神经网络（FCN）来进行维度的缩放，二是 1x1 卷积层，实现通道之间的线性变换；激活层采用 tanh 激活函数。

在本公开的一些实施例中，使用 Tukey lambda 分布建模读取噪声， $N_{read} \sim TL(\lambda; 0, \sigma_{TL})$ ，其中 σ_{TL} 表示尺度参数，在零均值噪声假设下，位置参数被设置为 0；所述行噪声值 N_r 从尺度参数为 σ_r 的零均值高斯分布中采样， $N_r \sim N(0, \sigma_r)$ ，然后将其作为对每一行像素点的偏移量进行相加；模拟电压信号

使用 ADC 被量化为离散值时会引入量化噪声 N_q , $N_q \sim U(-\frac{1}{2q}, \frac{1}{2q})$, 其中, q

为其中为量化步长, U 表示均匀分布。

在本公开的一些实施例中, 所述使用智能手机图像去噪数据集 SIDD, 该数据集使用了 5 个具有代表性的智能手机摄像头, 从 10 个场景中提取约 30000 个真实场景噪声图像, 该数据集可对降噪算法进行基准测试; 所述真实场景噪声图像使用该数据集中原始 raw 图像, 将原始图像数据集划分成 50 万个大小为 64x64 像素的图像块, 按照 7: 3 的比例划分训练集和测试集。

在本公开的一些实施例中, 所述使用传感器标定数据预训练标准化流模型的具体过程为: 使用训练集进行模型训练, 为了简单起见, 假设数据集中的噪声是空间不变的, 使用 PatchGan 鉴别器作为对抗训练的鉴别器, 将 SIDD 数据集划分成 64×64 大小的块, 批大小设置为 16, 所有的模型在单卡 3080T GPU 上被迭代训练 2×10^5 次, 使用 Adam 作为优化器, 学习率一开始被设置为 2×10^{-4} , 每迭代 5000 次学习率降低。

标准化流模型是近年来流行的一类生成式模型, 标准化流的过程是通过具有已知分布 (通常是正态分布) 的随机变量通过一系列可微、可逆映射的转换生成其他分布的过程。与其他生成式模型 GAN 和 VAE 相比, 基于标准化流的方法不会面临模型坍塌的问题, 它们有更为准确的采样和对概率密度的估计。

以下是对标准化流的简单介绍: 设 $x_0 \in R^D$ 是一个随机变量, 其概率密度函数 $p_x: R^D \rightarrow R$ 已知; $x_1, x_2 \dots x_N$ 是一系列随机变量且满足 $x_i = f_i(x_{i-1})$, $f_i: R^D \rightarrow R^D$ 是可微双射的转换函数; 若 $n = f(x_0) = f_N \circ f_{N-1} \circ \dots \circ f_1(x_0)$, 则 n 的概率密度函数如式 4 所示:

$$p(n) = p_{x_0}(g(n)) \prod_{j=1}^N |det J_j(g(n))|^{-1} \quad \langle \text{式 4} \rangle$$

其中, $g = g_1 \circ \dots \circ g_{N-1}$ 是 f 的反函数, $J_j = \partial f_j / \partial x_{j-1}$ 是第 j 个转换函数的雅可比式。

标准化流可以通过最大似然估计得到所求概率密度函数的参数值, 给定观测数据 $D = \{n_i\}_{i=1}^M$, 设转换函数 f_1, \dots, f_N 的参数分别由 $\theta = (\theta_1, \dots, \theta_N)$ 来表示, 观测数据的最大似然函数取对数后的值为 $\log p(D|\theta) = \sum_{i=1}^M \log p_{x_0}(g(n_i|\theta)) - \sum_{j=1}^N \log |det J_j(g(n_i|\theta), \theta_j)|$, 其中第一项是观测数据的对数似然, 第二项是转换函数带来的体积修正。选择具有零均值和恒等协方差的各向同性正态分布作为基

说明书

本测度函数，使用一组双射可微函数作为转换函数，进行噪声分布概率密度的估计。

根据上文提到的基于物理形成过程的噪声模型，设计了一种新的噪声图合成流程，仅通过测试噪声图像来估计噪声模型参数。由于图像噪声主要产生于线性原始空间，本发明主要研究了不受图像信号处理管道（ISP）影响的原始噪声建模和合成，对于常见的 CCD 和 CMOS 传感器，捕获的信号可以表示为：

$$I = C + N$$

其中 C 表示干净 *raw* 域图像， N 表示噪声，服从由干净 *raw* 域图像确定的隐分布，

$$N \sim F(C)$$

整体流程框架图如图 1 所示。

发明使用 kullback-Leibler (KL) 散度来度量真实噪声和采样噪声直方图之间的距离。本发明对比了其他四种方法：

- 1) AWGN，它假设每个像素点上都有独立的各向同性噪声；
- 2) G/P 是上文中提到的泊松高斯分布；
- 3) NoiseFlow 是基于标准化流，直接生成噪声的模型；
- 4) Contrastive learning 是文章《Estimating Fine-Grained Noise Model via Contrastive Learning》中提到的模型。

不同方法生成噪声 kl 散度值的比较结果如表 1 所示：

表 1 不同方法生成噪声 kl 散度值的比较结果

Dataset	AWGN	G/P	NoiseFlow	Contrsitive learning	Ours
S6	0.4793	0.1023	0.0617	0.0385	0.0213527
IP	0.8367	0.0514	0.0327	0.0100	0.0189742
GP	0.6254	0.0316	0.0756	0.0219	0.02293
N6	0.7321	0.0168	0.0731	0.0165	0.014326
G4	1.0987	0.0315	0.0519	0.0187	0.016943

如表 1 所示，经实验验证，本发明的方法在 SIDD 数据集三种不同类型的手持传感器上取得了提升。

说明书

通过使用噪声训练去噪器进一步说明了本方法噪声合成能力，如表 2 所示：

表 2 使用不同生成噪声训练去噪器的测试结果

Dataset	Sota	G/P	Ours
SID	44.50	42.35	45.12
ELD	45.44	42.46	45.84

实验证实，本发明提出的方法可以合成更贴近于真实 raw 域图像的噪声数据。

可以理解，本发明是通过一些实施例进行描述的，本领域技术人员知悉的，在不脱离本发明的精神和范围的情况下，可以对这些特征和实施例进行各种改变或等效替换。另外，在本发明的教导下，可以对这些特征和实施例进行修改以适应具体的情况及材料而不会脱离本发明的精神和范围。因此，本发明不受此处所公开的具体实施例的限制，所有落入本申请的权利要求范围内的实施例都属于本发明所保护的范围内。




图 1